



Segundo proyecto: Técnicas de aprendizaje de máquina

Diego Caballero Sarmiento

Liseth Lozano

Aura Atuesta

Pontificia Universidad Javeriana

Docente: Julio Omar Palacio Niño

Bogotá, Colombia

2024-3

Abstract: Resumen del problema abordado, análisis realizado y resultados obtenidos (máximo 150 palabras)

Introducción

El análisis de los datos históricos de accidentes viales ocurridos en los últimos años en distintas localidades de la ciudad busca entender los patrones que subyacen entre estos accidentes. En particular, el objetivo principal de esta investigación es identificar eventos de muertes ocasionadas en accidentes viales y zonas específicas dentro de la ciudad donde los patrones de accidentalidad sean similares, con el fin de poder caracterizar y agrupar estas zonas según sus características comunes. Este enfoque permitirá un mejor entendimiento de los factores que contribuyen a la ocurrencia de accidentes fatales y ayudará a implementar medidas preventivas más efectivas en las áreas de mayor riesgo.

Para abordar este objetivo, se utilizarán técnicas de agrupamiento como **K-means** y **clustering jerárquico**, que permitirán identificar grupos o clusters de zonas con patrones de accidentes similares. Estas técnicas proporcionarán una forma robusta de clasificar las zonas de la ciudad y detectar patrones ocultos en los datos.

Además de estas técnicas de agrupamiento, se utilizará un modelo que combine diversas metodologías de análisis para mejorar la precisión y la robustez de los resultados.


La pregunta de investigación principal que guía este estudio es: **¿Qué zonas de la ciudad presentan patrones de accidentalidad similares en cuanto a las muertes ocasionadas por accidentes viales?** A partir de la respuesta a esta pregunta, se podrá identificar no solo las áreas de alto riesgo, sino también los factores comunes que podrían estar influyendo en la ocurrencia de estos accidentes, como la infraestructura vial, el comportamiento de los conductores, o la proximidad a ciertos puntos críticos de la ciudad.

Aproximación al problema

En primer lugar, se llevó a cabo un análisis exploratorio de los datos con el fin de evaluar su calidad. Como resultado, se determinó que el conjunto de datos (filtrado por gravedad de accidentes con muertes) está compuesto por 3239 filas y 16 columnas, siendo la mayoría de las variables de tipo numérico. Adicionalmente, se detectaron valores nulos en las siguientes columnas:

- **LOCALIDAD:** 46 valores nulos
- **CIV:** 1701 valores nulos
- **PK_CALZADA:** 37974 valores nulos

Por otro lado, se generaron histogramas de las variables numéricas con el fin de visualizar la distribución de sus valores y obtener una mejor comprensión de su comportamiento.




Para el preprocesamiento de los datos, se seleccionaron únicamente los registros de la columna GRAVEDAD que corresponden a accidentes con muertes, de acuerdo con el enfoque del análisis. Esta selección permitió evitar redundancias y centrarse en las variables más relevantes. A continuación, se eligieron las siguientes variables para la construcción de los modelos: LATITUD, LONGITUD, CLASE_ACC y LOCALIDAD.

Las variables categóricas CLASE_ACC y LOCALIDAD fueron convertidas en variables numéricas mediante la técnica de codificación one-hot, esto es importante para los algoritmos de clustering como K-means requieren datos numéricos para realizar las agrupaciones. También se realizó la normalizaron las variables numéricas LATITUD y LONGITUD para que todas las variables tengan la misma escala, es esencial para evitar que las variables con mayor rango numérico dominen el proceso de clustering.

Resultados: Describa qué encontró al aplicar la técnica al problema

a) Agrupamiento con K-means

Se utilizó el método del codo para determinar el número óptimo de clusters.




Después de analizar los resultados del método del codo, se seleccionó **K = 3** como el número óptimo de clusters, ya que maximiza la separación entre los patrones de accidentalidad en las zonas de la ciudad y ofrece clusters más definidos y diferenciados.

Se evaluó la calidad del clustering utilizando tres métricas:


- Inercia (WCSS final): 77471.63988900791 es relativamente baja, lo que sugiere que los clusters son relativamente compactos.
- Coeficiente de silueta: 0.11397701321290757 es aceptable, muestra que la separación no es perfecta, pero es suficientemente para que los clusters sean útiles para este análisis.
- Calinski-Harabasz Score: 208.46132446302218, (entre escoger a $K = 2$ y $K=4$, **K=3** mostró tener el score más alto) lo que indica una mejor diferenciación entre clusters.

Se utilizó PCA para proyectar las características de los accidentes en dos componentes principales y graficar los puntos con colores representando cada cluster y su respectivo centroide.



La separación entre los clusters parece ser bastante buena ya que el algoritmo ha logrado identificar grupos distintos en los datos. Sin embargo, hay cierta superposición entre los clusters verde y amarillo, lo que indica que algunos datos pueden ser difíciles de clasificar con certeza.

Se generó un gráfico de siluetas para visualizar la cohesión y separación de los clusters.






Cluster 1: La mayoría de las muestras en este cluster tienen un coeficiente de silueta cercano a 0, puede ser que los clusters están muy cercanos entre sí.


Cluster 2: Las muestras en este cluster tienen un coeficiente de silueta un poco más alto que el Cluster 1, indicando una mejor separación de estos datos.

Cluster 3: Este cluster presenta los coeficientes de silueta más altos, puede que las muestras en este cluster estén bien separadas de los otros clusters.

Coefficiente de silueta promedio: En este caso, parece que el valor promedio es relativamente bajo, lo que podría indicar que la agrupación en tres clusters no es tan óptima para estos datos.


Se creó un gráfico de barras que mostró la distribución de la LOCALIDAD en cada cluster, lo que permitió identificar las zonas más representativas dentro de cada grupo de accidentalidad.





Cada cluster presenta una distribución de localidades característica. Esto sugiere que los factores que influyen en la accidentalidad varían considerablemente entre los diferentes grupos dependiendo de métricas como latitud, longitud y tipo de accidente. Por ejemplo, en el cluster 1 solo se encuentra Usaquén.

Se creó un gráfico de barras que mostró la frecuencia de diferentes tipos de accidentes en cada uno de los clusters identificados.




En el cluster 2, se observa una predominancia de atropellos, mientras que en el cluster 3, los choques son más comunes. Esto sugiere que hay factores particulares en esas áreas que favorecen la ocurrencia de estos tipos de accidentes. Por ejemplo, en Usaquén, se registran atropellos, choques y volcamientos, lo que indica una mayor diversidad en los tipos de accidentes en esa zona.

b) Modelo Clustering Jerárquico

Se aplicó un clustering jerárquico utilizando el método de Ward, basado en la minimización de la varianza dentro de los clusters, ya que este método presentó el mejor rendimiento en


términos de cohesión interna y separación entre los grupos en comparación con otros métodos. La elección del método de Ward se justificó por su capacidad para generar clusters más homogéneos y bien definidos. Además, para facilitar la visualización y comprensión de la estructura de los clusters, se generó un dendrograma a partir del resultado de la matriz de enlace, lo que permitió observar de manera clara las relaciones jerárquicas entre los clusters y determinar el número adecuado de grupos a través del análisis de las distancias de corte.



Se extrajeron las distancias de enlace de las últimas fusiones del resultado del clustering jerárquico. Estas distancias, que corresponden a las uniones más recientes entre los clusters, son particularmente relevantes ya que reflejan las fusiones más significativas en el proceso de agrupamiento. A partir del cálculo de estas distancias se realizó un gráfico de codo.



Se optó por una distancia máxima alrededor de 85, ya que en ese rango las fusiones aún representan una separación clara entre los grupos, y se generaron 5 clusters con ese umbral de distancia, los cuales se pueden observar en la siguiente imagen.




Como se observa en la imagen, los clusters están distribuidos en diferentes colores, representando grupos de puntos que fueron asignados a diferentes categorías en función de su similitud. Los clusters presentan una estructura variada: algunos son compactos y están bien


definidos, mientras que otros son más dispersos, lo cual sugiere una mayor variabilidad interna dentro de esos grupos.

La elección de una distancia de corte de 85 permite un balance adecuado entre cohesión y separación en los clústeres, como se refleja en la variedad de formas y tamaños en la imagen. En el centro del gráfico, los clústeres son más densos y cercanos, sugiriendo datos con características similares pero lo suficientemente distintas para formar grupos separados. Hacia los extremos, los clústeres son más definidos y separados, indicando una mayor distinción en esas áreas. La presencia de puntos aislados o clusters pequeños sugiere que algunos datos tienen características únicas o actúan como "outliers".

Por otra parte, se generó este gráfico de silueta, en donde se observa que la mayoría de los puntos tienen un coeficiente de silueta positivo, lo que indica que, en general, los puntos están bien asignados a sus respectivos clusters. Sin embargo, existe una variabilidad considerable en los valores del coeficiente de silueta, sugiriendo que algunos clusters son más cohesivos que otros. La línea vertical roja representa el coeficiente de silueta promedio, y el hecho de que muchos puntos se encuentren a la derecha de esta línea sugiere que, en promedio, los puntos están bien clasificados. No obstante, la presencia de algunos puntos con coeficientes de silueta cercanos a cero o incluso negativos indica que algunos puntos podrían estar mal asignados o en la frontera entre dos clusters.



Al graficar las localidades por cluster, se obtuvo:




c) Nuevo modelo


Hemos propuesto un modelo que integra múltiples técnicas de análisis, combinando métodos de reducción de dimensionalidad y clustering para mejorar la interpretación y segmentación de los datos. En particular, aplicamos Análisis de Componentes Principales (PCA) para reducir la dimensionalidad y retener la mayor parte de la varianza explicada. Posteriormente, utilizamos el algoritmo DBSCAN optimizado para agrupar los datos, y evaluamos la efectividad de diferentes parámetros mediante el puntaje de silueta. Además, empleamos técnicas de visualización como t-SNE y UMAP para entender mejor las proyecciones de los datos en espacios de menor dimensión.

Durante la optimización de los parámetros de DBSCAN, probamos diferentes valores para `min_samples` así evaluamos su impacto en el número de clusters y puntos de ruido. Los resultados mostraron que, con `min_samples` de 3, obtuvimos el mejor puntaje de silueta de 0.8859, indicando una buena cohesión y separación entre clusters. Como resultado, identificamos 62 clusters distintos y 28 puntos de ruido, lo que sugiere que los parámetros elegidos son efectivos para la agrupación de datos en este contexto.

Resultados de las visualizaciones:



Primero nos enfocamos en el análisis de los umbrales de varianza explicada y la selección del número de componentes principales (PCA). La gráfica muestra cómo la varianza explicada acumulada varía en función del número de componentes. Para alcanzar un umbral de 85% de varianza explicada, necesitamos 19 componentes; para un 90%, se requieren 21 componentes; y para un 95%, se necesitan 22 componentes. Esta información es crucial para determinar el balance óptimo entre la reducción de dimensionalidad y la retención de información en el conjunto de datos, permitiendo una mejor comprensión y visualización de los datos mediante técnicas como t-SNE y UMAP que presentaremos a continuación.



Se han visualizado los datos utilizando tres técnicas de reducción de dimensionalidad: PCA, t-SNE y UMAP. Cada una de estas técnicas ofrece una perspectiva diferente sobre la distribución de los datos y los clusters formados por el algoritmo DBSCAN. La proyección PCA muestra una representación más lineal y explicativa de la varianza, mientras que t-SNE y UMAP proporcionan vistas más detalladas sobre la estructura local y la agrupación de datos en espacios de menor dimensión. Estas visualizaciones ayudan a identificar la coherencia de los clusters y a detectar patrones que pueden no ser evidentes en el espacio original de alta dimensión.

Como conclusiones para finalizar, desarrollamos un modelo que combina técnicas de reducción de dimensionalidad y clustering para analizar y caracterizar patrones de accidentalidad vial en una ciudad. Aplicamos PCA para reducir la dimensionalidad del conjunto de datos, optimizamos los parámetros del algoritmo DBSCAN para identificar clusters de forma eficiente y utilizamos técnicas de visualización como t-SNE y UMAP para entender mejor la distribución de los datos. Los resultados muestran 62 clusters con un puntaje de silueta de 0.8859, lo que indica una excelente cohesión y separación entre los clusters. Este análisis proporciona insights valiosos para identificar y caracterizar zonas críticas de accidentalidad, ayudando a las autoridades a implementar medidas preventivas específicas.